📈 나만의 데이터로 미래를 예측하다

Orange3 선형 회귀 실습 보고서

— 두 변수의 관계를 스스로 찾아 예측 모델 만들기 —

학년 반 번호	10204	이름	김건희	제출일 9/23

🎯 미션 우리 주변에는 '하나가 늘면 다른 하나도 규칙적으로 변하는' 관계가 많습니다. 공부 시간과 성적, 기온과 아이스크림 판매량, 팔로워 수와 좋아요 수처럼요. 이번 활동에서는 내가 직접 고른 두 변수(x, y)의 데이터를 모아 산점도를 그리고, 노코딩 머신러닝(ML) 도구 Orange3로 선형 회귀 예측 모델을 만든 뒤, 그 예측이 믿을 만한지 스스로 검증합니다.

🏆 이 보고서는 수행평가① "Orange3 선형회귀 탐구" 입니다. **만점 30점 · 기본점수9점** 세 영역 각 10점(영역1·영역2·영역3)으로 채점합니다. **※ AI(생성형 AI 포함) 활용은 원칙적으로 금지합니다.**

영역 1	데이터 이해 및 회귀식 추정	[10점]

📋 평가요소 (배점 근거)

① 선형 관계가 나타나는 탐구 주제·데이터를 목적에 맞게 선정하고, 독립·종속 변수의 관계를 올바르게 파악하였는가? → 1-1

② 산점도를 근거로 회귀식(y=ax+b)을 합리적으로 추정하였는가? → 1-2-1·1-2-2

③ 기울기·절편의 의미를 데이터 맥락에서 설명하였는가? → 1-3

1-1 탐구 주제와 데이터 정하기 (내 탐구 설계)

💡 **어떤 관계를 예측해 볼까?** 아래는 아이디어일 뿐입니다. 관심 분야에서 자유롭게 골라도 좋고, 직접 새로운 주제를 만들어도 됩니다.

분야	예시 주제 (독립변수 x → 종속변수 y)
일상·소비	기온 → 아이스크림(또는 음료) 판매량 · 광고비 → 매출액
학습·생활	공부 시간 → 시험 점수 · 수면 시간 → 집중도 자기평가 점수
사회·미디어	팔로워 수 → 게시물 좋아요 수 · 영상 길이 → 조회수
과학·환경	음료 온도 → 얼음 녹는 시간 · 용수철에 매단 무게 → 늘어난 길이
스포츠·건강	키 → 몸무게 · 연습 시간 → 기록(초·점수)

✅ 좋은 데이터의 조건

· 두 변수 모두 숫자(연속형)이고, 하나가 변하면 다른 하나도 대체로 함께 변하는 관계일 것

· 데이터 개수는 최소 8개 이상 (많을수록 회귀선이 안정적)

· 직접 측정·설문하거나 공공데이터(KOSIS·기상자료개방포털 등)에서 수집 — 출처를 반드시 기록

탐구 주제	게임 제작·배급업 종사자 수와 국내 게임시장 매출액의 관계
독립변수 x	게임 제작·배급업 종사자 수(명)
종속변수 y	국내 게임산업 매출액(억 원)
데이터 출처	문화체육관광부·한국콘텐츠진흥원, 대한민국 게임백서
예상 관계	게임 제작·배급업 종사자 수가 많아질수록 국내 게임산업 매출액도 높아질 것으로 예상했다. 게임을 만들고 서비스하는 인력이 늘어나면 산업의 규모도 커질 수 있다고 생각했기 때문이다.

1-2-1 내 훈련 데이터 입력하기 (train.csv)

💡 수집한 훈련 데이터를 구글 시트나 엑셀에 입력하고 train.csv로 저장하세요. 첫 행은 변수 이름(x, y)으로 합니다.

독립변수 x (제작·배급업 종사자 수(명))	종속변수 y (게임산업 매출액(억 원))
35445	107223
33979	108945
34666	131423
37035	142902
39390	155750
44310	188855
45262	209913
48514	222149

	A	B	C
1	x	y	
2	35445	107223	
3	33979	108945	
4	34666	131423	
5	37035	142902	
6	39390	155750	
7	44310	188855	
8	45262	209913	
9	48514	222149	
10			
11			
12			
13			

1-2-2 규칙을 찾아 회귀식 손으로 추정하기

🧠 x가 일정하게 커질 때 y는 얼마씩 변하나요? 표에서 규칙을 찾아 직선의 식 y = a x + b 로 손으로 추정해 보세요.

x가 한 단위 커질 때 y는 약 8억 원만큼 증가한다. → 기울기 $a \approx 8$, 절편 $b \approx -153{,}000$. 따라서 $y = 8x - 153{,}000$ 로 예상한다.

1-3 기울기와 절편의 의미 해석

기울기 8은 게임 제작·배급업 종사자 수가 1명 많아질 때 예측 매출액이 약 8억 원 높아진다는 뜻이다. 절편 -153000 종사자 수가 0명일 때 매출액을 -153000억 원으로 예측한다는 의미이다. 하지만 내가 조사한 자료에는 종사자 수가 0명인 경우가 없고, 매출액이 음수가 되는 것도 현실에 맞지 않는다. 따라서 절편은 실제 매출액이라기보다 회귀선의 위치를 정하는 값으로 보는 것이 적절하다.

영역 2 | Orange3 예측 모델 구성 | [10점]

📋 평가요소 (배점 근거)

① train-test 데이터를 적절히 구성하였는가? → 1-2(train)·2-1(test)

② 워크플로우(File→Scatter Plot→Linear Regression→Predictions)를 올바르게 연결하였는가? → 2-2

③ 모델의 예측값을 산출하고 실제값(손 계산)과 비교하였는가? → 2-3

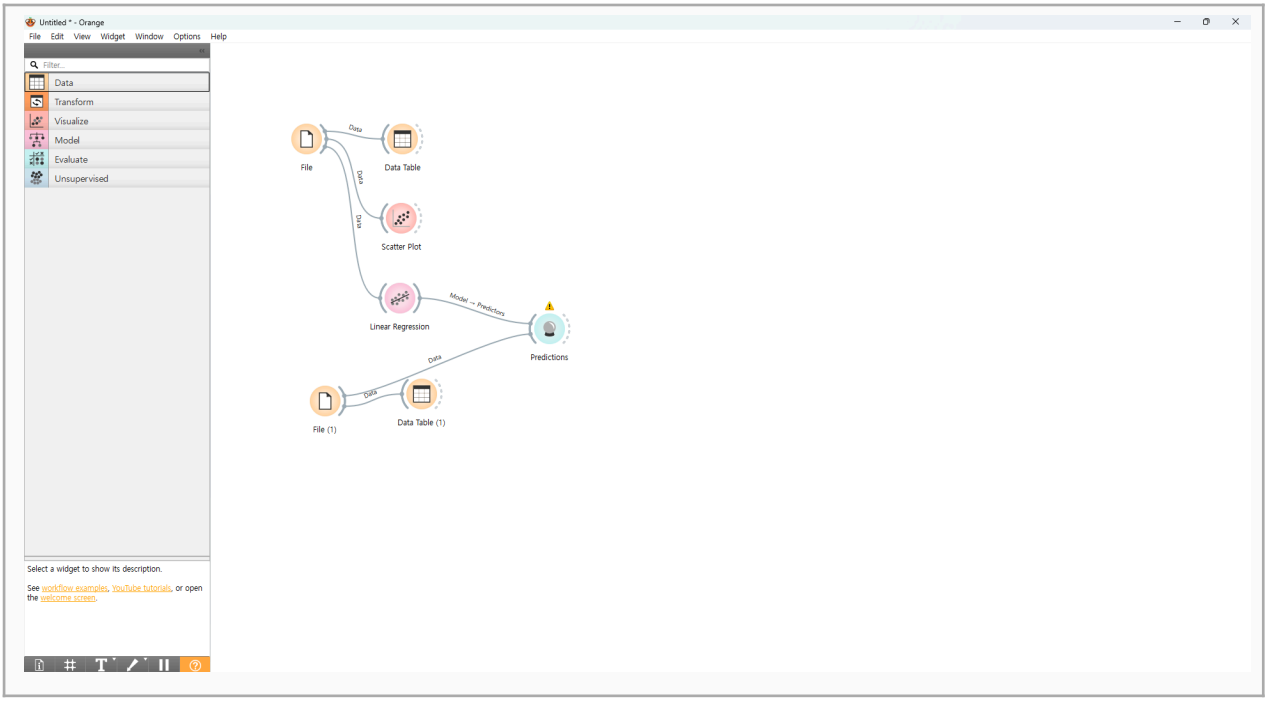
2-1 내 테스트 데이터 만들기 (test.csv)

💡 훈련 데이터 범위 안에서 x값 5개 정도를 골라 테스트 데이터(test.csv)를 만드세요. y열은 비워 둡니다.

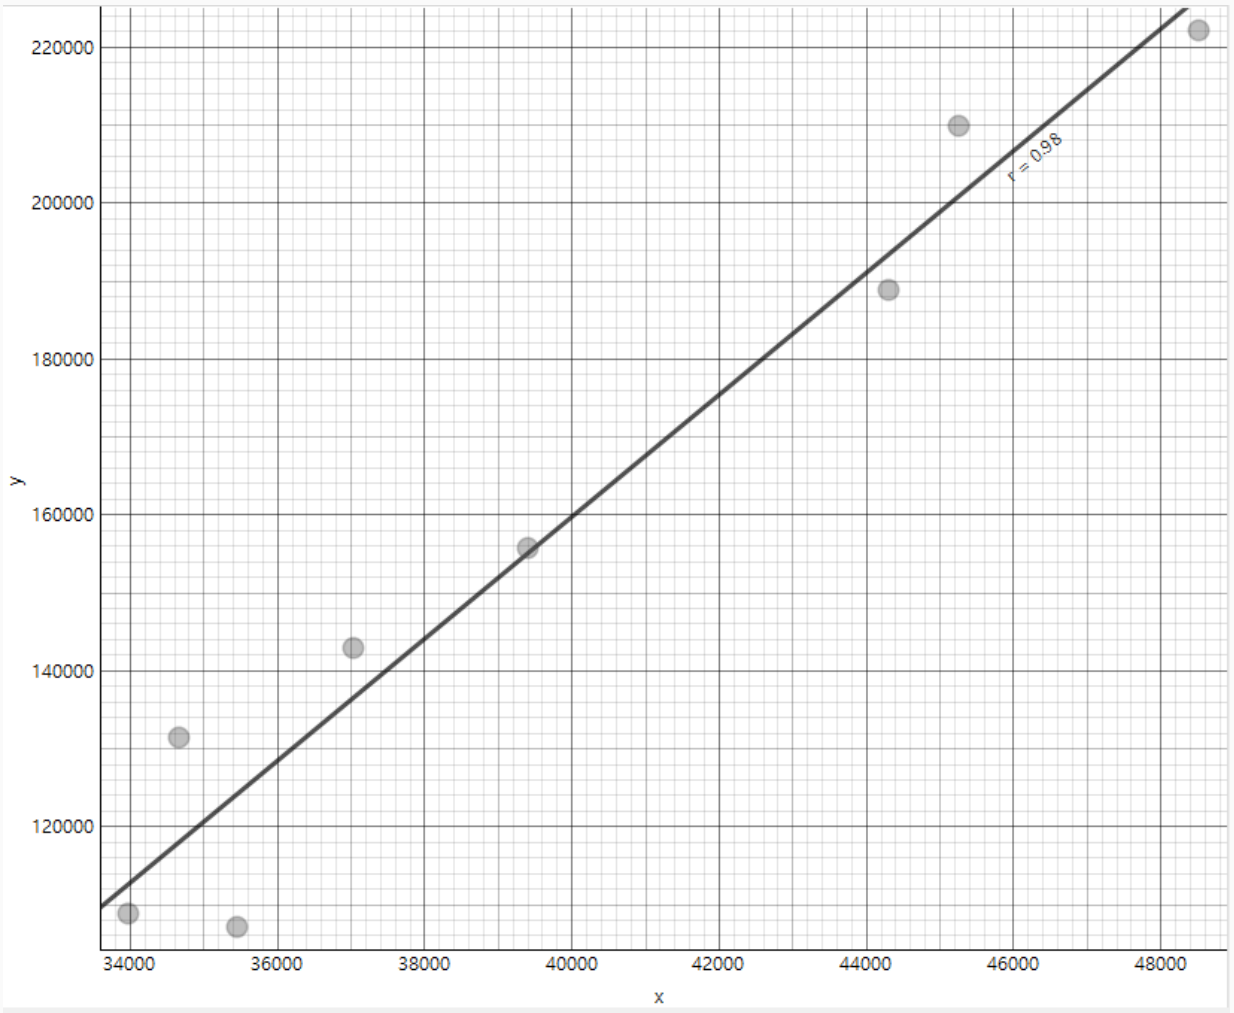
독립변수 x	종속변수 y (비움)
35000	?
38000	?
41000	?
44000	?
47000	?

2-2 Orange3 워크플로우 구성하기

> 📌 **워크플로우 순서**
>
> ① File 위젯 → train.csv 불러오기 (이름: train data)
>
> ② Data Table 위젯 연결 → 데이터 확인
>
> ③ Scatter Plot 위젯 연결 → 산점도 확인 (x축: 독립변수, y축: 종속변수)
>
> ④ Linear Regression 위젯 연결 → 모델 학습
>
> ⑤ 새 File 위젯 → test.csv 불러오기 (이름: test data)
>
> ⑥ Predictions 위젯 → 모델 + 테스트 데이터 연결

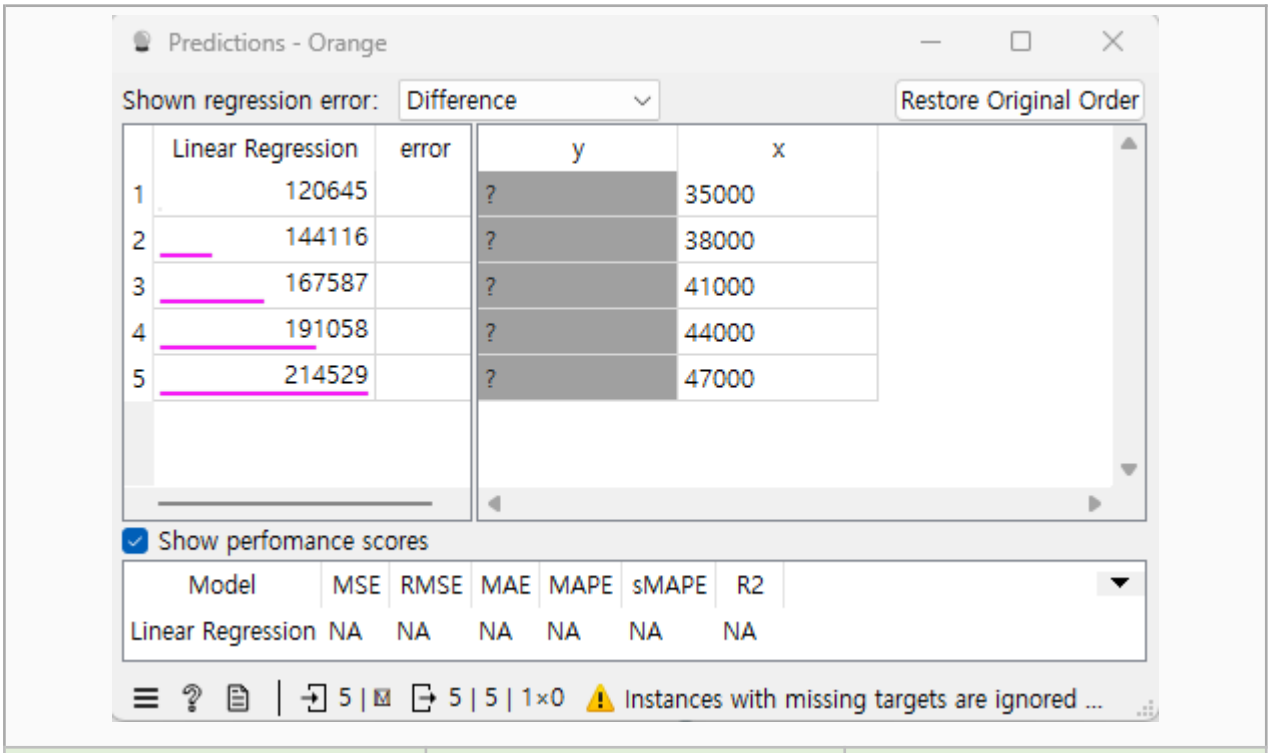


산점도 확인 및 관찰



데이터 점들을 보면 대체로 왼쪽 아래에서 오른쪽 위로 올라가는 것을 볼 수 있다. 종사자 수가 많을수록 매출액도 높아지는 양의 관계가 나타난 것이다. 몇몇 점은 회귀선에서 떨어져 있지만, 대부분은 회귀선 가까이에 있어 직선 경향이 비교적 뚜렷하다.

2-3 예측 결과 비교 (내 손 계산 vs Orange3)



x 값	내가 계산한 예측값 (y=ax+b)	Orange3 예측값
35000	127000	120645
38000	151000	144116
41000	175000	167587
44000	199000	191058
47000	223000	214529

영역 3 결과 검증 및 해석 [10점]

📋 평가요소 (배점 근거)

① 회귀선과 평가지표(R²·MAE·RMSE)로 예측 결과의 타당성을 검증하였는가? → 3-1

② 정비례·반비례 등 관계의 방향과 의미를 데이터 맥락에서 해석하였는가? → 3-2

③ 모델의 한계(외삽의 위험)를 탐구하고, 활동을 통해 배운 점을 성찰하였는가? → 3-3·3-4

3-1 회귀선으로 타당성 검증

손으로 구한 값과 Orange3의 예측값은 약 6000~8500억 원 정도 차이가 났다. 손으로 계산할 때 기울기와 절편을 간단한 숫자로 어림잡았기 때문에 차이가 생긴 것 같다. 그래도 두 결과 모두 종사자 수가 늘어날수록 매출액도 높아지는 모습을 보였다. 산점도의 점들도 대체로 회귀선 가까이에 있어, 모델이 데이터의 전체적인 경향을 어느 정도 잘 나타낸다고 생각한다.

3-1-2 모델 평가지표로 신뢰도 검증 (Test and Score · 심화)

🌟 **(심화) Test and Score로 모델의 신뢰도를 '숫자'로 검증하기**

① [Evaluate] → [Test and Score] 위젯을 추가한다.

② train data(File)를 Data로, Linear Regression을 Learner로 각각 연결한다.

③ 평가 방법은 Cross validation(교차검증, 기본값)으로 두고 아래 세 지표를 읽어 기록한다.

(MSE·MAPE도 함께 나오지만 R²·MAE·RMSE에 집중. RMSE = MSE의 제곱근)

평가지표	내가 기록한 값	이 값이 뜻하는 것 (내 해석)
R² (결정계수)	0.919	처음 보는 데이터에 대한 평가에서 매출액 변화의 약 91.9%를 모델이 설명했다는 뜻이다.
MAE (평균오차)	10	예측 매출액과 실제 매출액이 평균적으로 얼마나 차이 나는지 보여 준다. 단위는 억 원이다.
RMSE	117	예측 오차를 나타내며, 크게 빗나간 값의 영향을 MAE보다 더 많이 받는다. 단위는 억 원이다.

R²는 0.919로 1에 가까워서, 모델이 종사자 수와 매출액 사이의 관계를 비교적 잘 설명한다고 생각한다. RMSE는 큰 예측 오차의 영향을 더 많이 받기 때문에 MAE보다 크게 나올 수 있다. 실제 산점도에서도 회귀선에서 조금 떨어진 점들이 보인다. 교차검증은 일부 자료를 학습에 사용하지 않은 상태에서 예측하므로, 전체 자료에 맞춘 결과보다 점수가 낮게 나올 수 있다.

3-2 결과 해석 — 숫자 뒤의 의미

자료를 보면 게임 제작·배급업 종사자 수가 많을수록 국내 게임산업 매출액도 높아지는 경향이 있다. 기울기가 약 8이므로 종사자 수가 1명 많아질 때 예측 매출액은 약 8억 원 높아진다. 이런 결과는 게임산업의 인력 규모와 매출 규모를 함께 살펴볼 때 참고할 수 있다. 다만 인기 게임의 출시나 해외 진출도 매출에 영향을 주므로, 종사자 수만으로 매출액이 결정된다고 단정할 수는 없다.

3-3-1 한계 탐구 — 극단값 실험 (외삽의 위험)

🤔 학습 데이터 범위를 크게 벗어난 x값을 회귀식에 넣으면 예측이 현실적으로 말이 될까요?
외삽(Extrapolation)의 위험을 확인해 봅시다.

극단적인 x 값	모델 예측값 y	현실적으로 가능한가?
0명	약 -153185억 원	매출액이 음수이므로 불가능하다.

100000명	약 629186억 원	수치 자체는 가능하지만 예측을 믿기 어렵다.

종사자 수를 0명으로 넣었더니 매출액이 음수로 나와서 현실과 맞지 않았고 100000명도 내가 조사한 자료의 최대값인 48514명보다 훨씬 커서 예측값을 믿기 어려웠다.. 따라서 이 모델은 실제 자료가 있는 33979~48514명 범위에서 사용하는 것이 더 적절하다고 생각한다.

3-3-2 활동 성찰

📝 활동을 돌아보며 이번 활동에서 '어떤 문제 → 어떻게 해결 → 무엇을 배웠는지'와, 선형 회귀로 예측할 때 주의할 점(3-3의 외삽 실험과 연결)을 함께 정리하세요. 성실히 쓰면 세특(세부능력 및 특기사항) 작성의 좋은 소재가 됩니다.

📝 **활동 성찰** — '어떤 문제 → 어떻게 해결 → 무엇을 배웠는지' 흐름으로 쓰면 세특 작성의 좋은 소재가 됩니다.

처음에는 게임산업 전체 종사자 수를 사용하려고 했지만, 게임 제작과 직접 관련이 없는 직종도 포함되어 있어 범위가 너무 넓다고 생각했다. 그래서 제작·배급업 종사자 수만 골라 같은 연도의 매출액과 비교했다. 산점도에서는 종사자 수가 많을수록 매출액도 높아지는 경향이 보였고, 평가지표를 통해 예측이 얼마나 잘 맞는지도 확인했다. 종사자 수를 0명으로 넣었을 때 매출액이 음수로 나온 것을 보고, 자료 범위를 벗어난 예측은 그대로 믿으면 안 된다는 점을 배웠다.

📚 **핵심 개념 요약**

· 지도학습 : 정답(레이블)이 있는 데이터로 모델을 훈련시키는 방법

· 회귀(Regression) : 연속적인 숫자 값을 예측하는 문제 유형

· 선형 회귀 : $y = ax + b$ 직선으로 데이터의 패턴을 표현하는 알고리즘

· 기울기 a의 부호 : $a>0$이면 양의 관계(정비례), $a<0$이면 음의 관계(반비례)

· 외삽(Extrapolation)의 위험 : 학습 데이터 범위를 벗어난 예측은 신뢰하기 어려움

· 결정계수(R^2) : 모델이 데이터를 설명하는 비율(0~1). 단순 선형회귀에서는 상관계수의 제곱($R^2=r^2$)

· MAE / RMSE : 예측 오차의 크기(작을수록 좋음). RMSE는 큰 오차(이상치)에 더 민감

· 교차검증(Cross validation) : 데이터를 나눠, 학습에 쓰지 않은 부분으로 평가 → 모델의 '진짜 실력(일반화 성능)' 측정

· 훈련 vs 검증 성능 : 본 데이터엔 잘 맞고(훈련), 처음 보는 데이터엔 조금 못 맞음(검증). Test and Score 값이 검증 성능

🔎 수행평가 채점표 (교사 기입용)

채점 기준: 아래 참고

※ 저작권·데이터 윤리 미준수, 평가 윤리 미준수, AI 활용 금지 원칙 위반 등 부적절 상황 발생 시 해당 영역 0점 처리.

평가영역	배점	채점 기준 (해당 점수에 ○)	획득 점수
[영역1] 데이터 이해 및 회귀식 추정	10점	10 · 8 · 6 · 4	
[영역2] Orange3 예측 모델 구성	10점	10 · 8 · 6 · 4	
[영역3] 결과 검증 및 해석	10점	10 · 7 · 4 · 1	
합계	**30점**	기본점수 9점	**/ 30**